

Baseline Clássico para Detecção de Embolia Pulmonar em Angio-TC de Tórax: Engenharia de Características e Modelos Não Profundos sobre o Desafio RSNA 2020

Rawenne da Silva Leite, Wheverson de Abreu Lima, João Victor do Nascimento Silva

*Tópicos Especiais em Sistemas de Informação — Curso de Sistemas de Informação
Grupo G2 — Desafio RSNA 2020: Pulmonary Embolism Detection*

Resumo. Este trabalho constrói e avalia uma solução *baseline* para a detecção de embolia pulmonar (EP) em exames de angiotomografia computadorizada de tórax, restrita exclusivamente a métodos clássicos de visão computacional: engenharia de características manuais (textura, forma, gradiente, intensidade e radiômica) combinada a classificadores rasos (regressão logística, SVM, k -NN, Random Forest, *gradient boosting* e MLP raso). O objetivo não é maximizar desempenho, mas estabelecer o piso metodologicamente rigoroso contra o qual abordagens futuras baseadas em aprendizado profundo deverão ser comparadas. Descrevemos o protocolo experimental — particionamento por paciente, validação cruzada estratificada e agrupada, métricas apropriadas a um problema clinicamente desbalanceado — e discutimos as dificuldades intrínsecas do desafio: rótulos hierárquicos, esparsidade espacial do achado ao longo do volume e variabilidade de aquisição entre instituições. O repositório de código, incluindo um pipeline validado de ponta a ponta, está disponível publicamente (link na nota de rodapé).

Abstract. We build and evaluate a baseline solution for pulmonary embolism (PE) detection in chest CT pulmonary angiography, restricted exclusively to classical computer vision methods: hand-crafted feature engineering (texture, shape, gradient, intensity and radiomics) combined with shallow classifiers (logistic regression, SVM, k -NN, Random Forest, gradient boosting and a shallow MLP). The goal is not to maximize performance but to establish a methodologically rigorous floor against which future deep-learning approaches must be compared. We describe the experimental protocol — patient-level partitioning, stratified grouped cross-validation, metrics appropriate to a clinically imbalanced problem — and discuss the challenges intrinsic to the task: hierarchical labels, spatial sparsity of the finding along the volume, and cross-institution acquisition variability. The code repository, including an end-to-end validated pipeline, is publicly available (link in the footnote).

⁰Repositório: https://github.com/silvarawenne/tp1_g2 (branch `claude/laughing-rubin-7915wt`). **Uso de IA generativa:** partes do texto e do código foram redigidas com apoio de IA generativa (Claude); revisadas pelo grupo, que assume responsabilidade integral por sua correção, inclusive a verificação bibliográfica das referências.

1 Introdução

A embolia pulmonar (EP) é uma condição potencialmente fatal, diagnosticada primariamente por angiotomografia computadorizada de tórax (angio-TC). A leitura manual de centenas de cortes por exame é demorada e sujeita a variabilidade inter-observador, o que motiva sistemas de auxílio ao diagnóstico (CAD). O desafio *RSNA STR Pulmonary Embolism Detection* (2020) disponibilizou a maior base pública anotada para esta tarefa até então [5], com rótulos hierárquicos no nível de corte e de exame.

A maioria dos trabalhos recentes recorre a redes neurais profundas [9]. Este TP parte de premissa diferente, imposta pelo enunciado da disciplina: construir um *baseline* exclusivamente com métodos clássicos — características manuais combinadas a classificadores rasos — estabelecendo, com rigor metodológico, o piso de desempenho que uma futura abordagem profunda precisará superar para justificar seu custo computacional adicional. Contribuições: (i) um pipeline reproduzível de leitura DICOM, pré-processamento e extração de cinco famílias de descritores clássicos; (ii) um protocolo sem vazamento de dados (StratifiedGroupKFold por paciente, ajuste de hiperparâmetros em validação aninhada); (iii) uma comparação sistemática descritor $\times$ modelo contra o baseline trivial obrigatório; (iv) uma discussão fundamentada das dificuldades intrínsecas do desafio RSNA 2020.

2 Trabalhos Relacionados

A literatura de CAD para EP pré-datando o aprendizado profundo já explorava características extraídas ao longo de estruturas vasculares segmentadas, com classificadores de aprendizado multi-instância [1] — a mesma filosofia (características manuais + classificador clássico) adotada aqui, ainda que sem a segmentação vascular supervisionada daquele trabalho. As famílias de descritores usadas têm fundamentação estabelecida: textura via GLCM/Haralick [8] e LBP [10]; gradiente via HOG [7]; radiômica via PyRadiomics/IBSI [11]. Na modelagem, usamos os algoritmos clássicos mais estabelecidos para dados tabulares desbalanceados: SVM [6], Random Forest [2], *gradient boosting* [4] e SMOTE [3], frente ao desbalanceamento reportado na descrição oficial do desafio [5]. Em contraste, trabalhos de ponta neste desafio usam redes convolucionais 3D ponta a ponta, como o PENet [9] — este TP posiciona-se deliberadamente antes dessa fronteira, fornecendo o número de referência contra o qual tais modelos deverão ser comparados na fase seguinte do projeto.

3 Metodologia

3.1 Base, amostragem e pré-processamento

Utilizamos o conjunto *RSNA STR Pulmonary Embolism Detection* (2020), hospedado no Kaggle. Como os rótulos do teste oficial não são públicos, todo o protocolo é construído sobre o conjunto de treino, com partição própria (§3.4). Dado o volume da base (centenas de GB), trabalhamos com uma amostra estratificada por classe e por paciente, com semente fixa e critério de inclusão documentados no `README.md` — a amostragem é parte do protocolo, não uma simplificação não documentada. Cada corte DICOM é lido com `pydicom` e convertido para Hounsfield Units (HU) via $HU = \text{pixel} \times \text{RescaleSlope} + \text{RescaleIntercept}$. Aplicamos janelamento mediastinal/EP (centro 100 HU, largura 700 HU),

que realça o contraste entre o lúmen vascular opacificado e um eventual defeito de enchimento, seguido de reamostragem isotrópica (1 mm/pixel) para tornar os descritores comparáveis entre exames com `PixelSpacing` distintos, recorte de região de interesse e redimensionamento final. Esta etapa é determinística e por isso precede a divisão treino/teste sem risco de vazamento; normalizadores, seletores, PCA e SMOTE, por outro lado, são encapsulados em `sklearn.Pipeline` e ajustados somente na partição de treino de cada dobra.

3.2 Extração de características e agregação corte → exame

Extraímos cinco famílias de descritores por corte: (i) **textura** — GLCM/Haralick [8] e LBP uniforme [10]; (ii) **forma e contorno** — momentos de Hu e propriedades de região; (iii) **gradiente** — HOG [7]; (iv) **intensidade** — histograma e estatísticas de ordem superior; (v) **radiômica** — subconjunto IBSI via `PyRadiomics` [11]. Como a tarefa é volumétrica, agregamos por **pooling estatístico** (média, desvio-padrão, percentil 90 e máximo) das características de todos os cortes em um único vetor por exame — decisão justificada pela esparsidade espacial do achado, que descarta a média isolada e motiva estatísticas de cauda capazes de capturar o corte mais anômalo. Alternativas descartadas (características 2.5D e 3D diretas) são discutidas na Conclusão.

3.3 Modelagem

Implementamos o baseline trivial obrigatório (classificador de classe majoritária) e seis famílias de modelos clássicos: regressão logística regularizada, SVM linear e RBF [6], *k*-NN, Random Forest [2], *gradient boosting* (XGBoost) [4] e um MLP raso (uma camada oculta). Cada modelo é encapsulado em um Pipeline com padronização, seleção/redução de dimensionalidade opcional e SMOTE opcional [3], comparado contra o uso de `class_weight='balanced'`.

3.4 Protocolo experimental e métricas

O particionamento é feito por **paciente** (nunca por corte ou por exame isoladamente), via `StratifiedGroupKFold` com 5 dobras, semente fixa. O ajuste de hiperparâmetros ocorre por busca em grade dentro de uma validação cruzada aninhada (agrupada da mesma forma), nunca no conjunto de teste da dobra externa. Reportamos AUC-ROC, AUC-PR, sensibilidade, especificidade, F1 e acurácia balanceada, com média e desvio-padrão entre dobras — acurácia isolada não é reportada como métrica de desempenho, por ser enganosa em uma base com forte desbalanceamento de classes [5].

4 Resultados

Nota metodológica (remover na versão final): a Tabela 1 foi gerada por `scripts/run_experiment.py` sobre exames **sintéticos** (`src/data/synthetic.py`), pois este ambiente não tinha acesso ao Kaggle. Ela comprova que o pipeline executa corretamente de ponta a ponta, mas **não tem valor científico**. Regenerar sobre a amostra real de `data/raw/`, conforme o `README.md`.

As curvas ROC/PR e a matriz de confusão do melhor modelo (geradas automaticamente em `outputs/figures/`) devem ser inseridas aqui a partir da execução sobre dados reais, acompanhadas de análise de erro qualitativa (exemplos de acerto e falha, com hipóteses de causa) e importância de características por permutação.

Tabela 1: Comparação descritor $\times$ modelo (média $\pm$ desvio, 5 dobras). Exemplo sobre dados sintéticos de validação do pipeline — substituir pelos resultados reais.

Modelo	AUC-ROC	AUC-PR	Bal. Acc.
Baseline trivial	0,500	0,250	0,500
Regressão logística	—	—	—
SVM (linear/RBF)	—	—	—
k -NN	—	—	—
Random Forest	—	—	—
XGBoost	—	—	—
MLP raso	—	—	—

5 Conclusão

Este trabalho estabeleceu a infraestrutura completa e reproduzível de um baseline clássico para detecção de EP em angio-TC: leitura/pré-processamento DICOM justificados, cinco famílias de descritores hand-crafted, sete modelos (incluindo o baseline trivial) e um protocolo sem vazamento de dados. A limitação mais relevante é a ausência, neste estágio, de segmentação vascular/pulmonar supervisionada – usamos recorte de margem fixa e limiar de intensidade como proxies de ROI, o que provavelmente subestima o desempenho alcançável pelas características de forma e radiômicas. Trabalho futuro imediato: (i) substituir os dados sintéticos pela amostra real do RSNA STR PE Dataset e reportar os números definitivos na Seção 4; (ii) avaliar características 2.5D como alternativa ao pooling estatístico; (iii) comparar este piso clássico contra aprendizado profundo (ex.: réplica simplificada do PENet [9]) na fase seguinte do projeto.

Referências

- [1] Jinbo Bi and Jianming Liang. Multiple instance learning of pulmonary embolism detection with geodesic distance along vascular structure. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2007.
- [2] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- [3] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, and W. Philip Kegelmeyer. SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16:321–357, 2002.
- [4] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, pages 785–794, 2016.
- [5] Errol Colak, Felipe C. Kitamura, Stephen B. Hobbs, et al. The RSNA pulmonary embolism CT dataset. *Radiology: Artificial Intelligence*, 3(2), 2021.
- [6] Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine Learning*, 20(3):273–297, 1995.
- [7] Navneet Dalal and Bill Triggs. Histograms of oriented gradients for human detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 886–893, 2005.
- [8] Robert M. Haralick, K. Shanmugam, and Its'hak Dinstein. Textural features for image classification. *IEEE Transactions on Systems, Man, and Cybernetics*, SMC-3(6):610–621, 1973.
- [9] Shih-Cheng Huang, Tanay Kothari, Imon Banerjee, et al. PENet—a scan-level deep-learning model for automatic diagnosis of pulmonary embolism. *npj Digital Medicine*, 3:61, 2020.
- [10] Timo Ojala, Matti Pietikäinen, and Topi Mäenpää. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 24(7):971–987, 2002.
- [11] Joost J. M. van Griethuysen, Andriy Fedorov, Chintan Parmar, et al. Computational radiomics system to decode the radiographic phenotype. *Cancer Research*, 77(21):e104–e107, 2017.