

Baseline Clássico para Detecção de Embolia Pulmonar em Angio-TC de Tórax: Engenharia de Características e Modelos Não Profundos sobre o Desafio RSNA 2020

Rawenne da Silva Leite, Wheverson de Abreu Lima, João Victor do Nascimento Silva

*Tópicos Especiais em Sistemas de Informação — Curso de Sistemas de Informação
Grupo G2 — Desafio RSNA 2020: Pulmonary Embolism Detection*

Resumo. Este trabalho constrói e avalia uma solução *baseline* para a detecção de embolia pulmonar (EP) em exames de angiotomografia computadorizada de tórax, restrita exclusivamente a métodos clássicos de visão computacional: engenharia de características manuais (textura, forma, gradiente, intensidade e radiômica) combinada a classificadores rasos (regressão logística, SVM, k -NN, Random Forest, *gradient boosting* e MLP raso). O objetivo não é maximizar desempenho, mas estabelecer o piso metodologicamente rigoroso contra o qual abordagens futuras baseadas em aprendizado profundo deverão ser comparadas. Descrevemos o protocolo experimental — particionamento por paciente, validação cruzada estratificada e agrupada, métricas apropriadas a um problema clinicamente desbalanceado — e discutimos as dificuldades intrínsecas do desafio: rótulos hierárquicos, esparsidade espacial do achado ao longo do volume e variabilidade de aquisição entre instituições. Reportamos resultados preliminares sobre uma amostra piloto real (6 exames), suficientes para validar o pipeline de ponta a ponta sobre dados clínicos genuínos, ainda que insuficientes para conclusões estatísticas robustas. O repositório de código está disponível publicamente (link na nota de rodapé).

Abstract. We build and evaluate a baseline solution for pulmonary embolism (PE) detection in chest CT pulmonary angiography, restricted exclusively to classical computer vision methods: hand-crafted feature engineering (texture, shape, gradient, intensity and radiomics) combined with shallow classifiers (logistic regression, SVM, k -NN, Random Forest, gradient boosting and a shallow MLP). The goal is not to maximize performance but to establish a methodologically rigorous floor against which future deep-learning approaches must be compared. We describe the experimental protocol — patient-level partitioning, stratified grouped cross-validation, metrics appropriate to a clinically imbalanced problem — and discuss the challenges intrinsic to the task: hierarchical labels, spatial sparsity of the finding along the volume, and cross-institution acquisition variability. We report preliminary results on a real pilot sample (6 exams), sufficient to validate the end-to-end pipeline on genuine clinical data, though too small for robust statistical conclusions. The code repository is publicly available (link in the footnote).

⁰Repositório:

https://github.com/silvarawenne/tp1_g2

(branch

1 Introdução

A embolia pulmonar (EP) é uma condição potencialmente fatal, diagnosticada primariamente por angiotomografia computadorizada de tórax (angio-TC). A leitura manual de centenas de cortes por exame é demorada e sujeita a variabilidade inter-observador, o que motiva sistemas de auxílio ao diagnóstico (CAD). O desafio *RSNA STR Pulmonary Embolism Detection* (2020) disponibilizou a maior base pública anotada para esta tarefa até então [5], com rótulos hierárquicos no nível de corte e de exame.

A maioria dos trabalhos recentes recorre a redes neurais profundas [9]. Este TP parte de premissa diferente, imposta pelo enunciado da disciplina: construir um *baseline* exclusivamente com métodos clássicos — características manuais combinadas a classificadores rasos — estabelecendo o piso de desempenho que uma futura abordagem profunda precisará superar para justificar seu custo computacional adicional. Contribuições: (i) um pipeline reprodutível de leitura DICOM, pré-processamento e extração de cinco famílias de descritores clássicos; (ii) um protocolo sem vazamento de dados (StratifiedGroupKFold por paciente); (iii) uma comparação sistemática descritor $\times$ modelo contra o baseline trivial; (iv) discussão das dificuldades intrínsecas do desafio RSNA 2020.

2 Trabalhos Relacionados

A literatura de CAD para EP pré-datando o aprendizado profundo já explorava características extraídas ao longo de estruturas vasculares segmentadas, com classificadores de aprendizado multi-instância [1] — a mesma filosofia adotada aqui, ainda que sem a segmentação vascular supervisionada daquele trabalho. As famílias de descritores usadas têm fundamentação estabelecida: textura via GLCM/Haralick [8] e LBP [10]; gradiente via HOG [7]; radiômica via PyRadiomics/IBSI [11]. Na modelagem, usamos os algoritmos clássicos mais estabelecidos para dados tabulares desbalanceados: SVM [6], Random Forest [2], *gradient boosting* [4] e SMOTE [3], frente ao desbalanceamento reportado na descrição oficial do desafio [5]. Em contraste, trabalhos de ponta neste desafio usam redes convolucionais 3D, como o PENet [9] — este TP posiciona-se deliberadamente antes dessa fronteira, como número de referência a ser superado.

3 Metodologia

3.1 Base, amostragem e pré-processamento

Utilizamos o conjunto *RSNA STR Pulmonary Embolism Detection* (2020), hospedado no Kaggle (7.279 exames de treino; 4.911 negativos e 2.368 positivos para EP). Como os rótulos do teste oficial não são públicos, todo o protocolo é construído sobre o conjunto de treino, com partição própria (§3.4). Dado o volume da base (~750 GB), a amostra piloto foi extraída em duas rodadas por um Kaggle Notebook (dado já residente no servidor, sem download local do conjunto completo): 22 exames — 11 positivos e 11 negativos, sementes fixas (42 e 43) — com 6–15 cortes aleatórios por exame (variável por rodada, limitado pela transferência de arquivo do ambiente); critério reprodutível em README.md e

claude/laughing-rubin-7915wt). **Uso de IA generativa:** partes do texto e do código foram redigidas com apoio de IA generativa (Claude); revisadas pelo grupo, que assume responsabilidade integral por sua correção, inclusive a verificação bibliográfica das referências.

`data/raw/real_sample_manifest.json`. Cada corte é lido com `pydicom` e convertido para Hounsfield Units (HU) via $HU = \text{pixel} \times \text{RescaleSlope} + \text{RescaleIntercept}$. Aplicamos janelamento mediastinal/EP (centro 100 HU, largura 700 HU), que realça o contraste entre o lúmen vascular opacificado e um eventual defeito de enchimento, seguido de reamostragem isotrópica (1 mm/pixel) para tornar os descritores comparáveis entre exames com `PixelSpacing` distintos, recorte de região de interesse e redimensionamento final. Esta etapa é determinística e por isso precede a divisão treino/teste sem risco de vazamento; normalizadores, seletores, PCA e SMOTE, por outro lado, são encapsulados em `sklearn.Pipeline` e ajustados somente na partição de treino de cada dobra.

3.2 Extração de características e agregação corte → exame

Extraímos cinco famílias de descritores por corte: (i) **textura** — GLCM/Haralick [8] e LBP uniforme [10]; (ii) **forma e contorno** — momentos de Hu e propriedades de região; (iii) **gradiente** — HOG [7]; (iv) **intensidade** — histograma e estatísticas de ordem superior; (v) **radiômica** — subconjunto IBSI via `PyRadiomics` [11]. Como a tarefa é volumétrica, agregamos por **pooling estatístico** (média, desvio-padrão, percentil 90 e máximo) das características de todos os cortes em um único vetor por exame — decisão justificada pela esparsidade espacial do achado, que descarta a média isolada e motiva estatísticas de cauda capazes de capturar o corte mais anômalo. Alternativas descartadas (características 2.5D e 3D diretas) são discutidas na Conclusão.

3.3 Modelagem

Implementamos o baseline trivial obrigatório e seis famílias de modelos clássicos: regressão logística regularizada, SVM linear e RBF [6], k -NN, Random Forest [2], *gradient boosting* (XGBoost) [4] e um MLP raso. Cada modelo é encapsulado em um `Pipeline` com padronização, seleção/redução opcional e SMOTE opcional [3], comparado contra `class_weight='balanced'`.

3.4 Protocolo experimental e métricas

O particionamento é feito por **paciente** (nunca por corte ou por exame isoladamente), via `StratifiedGroupKFold` com 5 dobras, semente fixa. O ajuste de hiperparâmetros ocorre por busca em grade dentro de uma validação cruzada aninhada (agrupada da mesma forma), nunca no conjunto de teste da dobra externa. Reportamos AUC-ROC, AUC-PR, sensibilidade, especificidade, F1 e acurácia balanceada, com média e desvio-padrão entre dobras — acurácia isolada não é reportada como métrica de desempenho, por ser enganosa em uma base com forte desbalanceamento de classes [5].

4 Resultados

Nota sobre a amostra (piloto pequeno): os números abaixo vêm da execução real de `scripts/run_experiment.py` sobre os 22 exames **reais** descritos em §3.1, não sintéticos, com ajuste de hiperparâmetros em validação aninhada. Com 11 exames por classe, as métricas ainda têm variância relevante e **não devem ser lidas como benchmark definitivo**, mas já são suficientes para uma leitura comparativa inicial entre famílias de modelos.

Regressão logística e MLP raso ficaram acima do baseline trivial (0,500); XGBoost e SVM linear ficaram *abaixo* — com $N=22$ para 8 modelos, alguns superajustam às centenas de características extraídas. Matriz de confusão fora-de-dobra da regressão logística:

Tabela 1: Comparação descritor $\times$ modelo (média $\pm$ desvio, 5 dobras, 22 exames reais: 11 positivos + 11 negativos).

Modelo	AUC-ROC	AUC-PR	Bal. Acc.
Regressão logística	0,783 $\pm$ 0,194	0,840 $\pm$ 0,183	0,633 $\pm$ 0,100
MLP raso	0,767 $\pm$ 0,122	0,857 $\pm$ 0,081	0,700 $\pm$ 0,194
k-NN	0,600 $\pm$ 0,276	0,723 $\pm$ 0,225	0,633 $\pm$ 0,251
SVM (RBF)	0,600 $\pm$ 0,122	0,686 $\pm$ 0,112	0,500 $\pm$ 0,158
Random Forest	0,575 $\pm$ 0,350	0,701 $\pm$ 0,215	0,500 $\pm$ 0,279
Baseline trivial	0,500 $\pm$ 0,000	0,500 $\pm$ 0,063	0,500 $\pm$ 0,000
XGBoost	0,300 $\pm$ 0,292	0,549 $\pm$ 0,204	0,367 $\pm$ 0,145
SVM (linear)	0,267 $\pm$ 0,162	0,514 $\pm$ 0,127	0,467 $\pm$ 0,251




Figura 1: Curva ROC fora-de-dobra da regressão logística (melhor AUC-ROC médio), $N=22$.

6 VN, 5 FP, 3 FN, 8 VP (sensibilidade = 72,7%, especificidade = 54,5%). **Erro qualitativo:** os 8 erros distribuem-se de forma equilibrada entre falsos positivos e negativos, sem exame específico como outlier de score extremo — diferente do piloto $N=6$, consistente com a hipótese de que mais dados diluem erros idiossincráticos de exames individuais.

5 Conclusão

Este trabalho estabeleceu a infraestrutura completa e reproduzível de um baseline clássico para detecção de EP em angio-TC, validado sobre uma amostra piloto **real** de 22 exames (ampliada a partir de um piloto inicial de 6). Regressão logística e MLP raso superaram consistentemente o baseline trivial (AUC-ROC 0,78 e 0,77 vs. 0,50); XGBoost e SVM linear ficaram abaixo — com $N=22$ para 8 modelos, superajuste ainda é esperado. A ausência de segmentação vascular/pulmonar supervisionada é a segunda limitação relevante. Trabalho futuro: (i) ampliar a amostra para centenas de exames; (ii) seleção de características mais agressiva para reduzir superajuste; (iii) comparar contra aprendizado profundo (ex.: réplica do PENet [9]).

Referências

- [1] Jinbo Bi and Jianming Liang. Multiple instance learning of pulmonary embolism detection with geodesic distance along vascular structure. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2007.
- [2] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- [3] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, and W. Philip Kegelmeyer. SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16:321–357, 2002.
- [4] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, pages 785–794, 2016.
- [5] Errol Colak, Felipe C. Kitamura, Stephen B. Hobbs, et al. The RSNA pulmonary embolism CT dataset. *Radiology: Artificial Intelligence*, 3(2), 2021.
- [6] Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine Learning*, 20(3):273–297, 1995.
- [7] Navneet Dalal and Bill Triggs. Histograms of oriented gradients for human detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 886–893, 2005.
- [8] Robert M. Haralick, K. Shanmugam, and Its'hak Dinstein. Textural features for image classification. *IEEE Transactions on Systems, Man, and Cybernetics*, SMC-3(6):610–621, 1973.
- [9] Shih-Cheng Huang, Tanay Kothari, Imon Banerjee, et al. PENet—a scan-level deep-learning model for automatic diagnosis of pulmonary embolism. *npj Digital Medicine*, 3:61, 2020.
- [10] Timo Ojala, Matti Pietikäinen, and Topi Mäenpää. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 24(7):971–987, 2002.
- [11] Joost J. M. van Griethuysen, Andriy Fedorov, Chintan Parmar, et al. Computational radiomics system to decode the radiographic phenotype. *Cancer Research*, 77(21):e104–e107, 2017.